这篇全文论文在被接受和发表之前，已按照 IEEE 仪器与测量学会的要求进行了同行评审。

一种用于越野环境中车辆车轮打滑预测的混合深度学习方法

Mustofa Basri, Areg Karapetyan, Bilal Hassan, Majid Khonji and Jorge Dias

2022 IEEE International Symposium on Robotic and Sensors Environments (ROSE) | 978-1-6654-8923-2/22/$31.00 ©2022 IEEE | DOI: 10.1109/ROSE56499.2022.9977432

*摘要——车轮*打滑预测对于地面车辆的安全导航和最优轨迹规划至关重要，尤其是在穿越沙地、砾石地或泥地等未铺设路面的越野行驶时。然而，由于测量与车轮与地面相互作用相关的物理参数涉及众多复杂过程，精确计算轮胎滑移量十分困难。以往大多数研究都侧重于开发适用于探测车或差速驱动机器人等的滑移预测模型，而对类似汽车的机器人则关注较少。为此，本研究提出了一种混合深度学习方法，以解决两个关键问题：（1）识别车辆行驶的地形类型；（2）在不平整和无结构的路面上估计车轮滑移量。首先，利用先进的模拟器进行了大量数据收集，构建了一个包含各种地形、速度范围、坡度和操作的充分描述性数据集（504,000 个样本）。然后，鉴于地形类型与车轮滑移量之间的密切关联，我们提出了一种轻量级卷积神经网络（CNN），称为TerrainNet，用于准确的地形分类。最后，利用 TerrainNet 的预测能力，我们训练并比较了几种经典机器学习和深度学习回归技术的性能，即多层感知器（MLP）、随机森林（RF）和极端梯度提升（XGB）。仿真结果表明，所提出的卷积神经网络能够准确区分地形（平均准确率＞99%），使得所采用的机器学习模型能够进行精确的车轮打滑估计（平均均方根误差＜0.03）。

*索引词——地形*识别、滑移估计、机器学习、卷积神经网络、越野驾驶。

I. 简介

开发适用于非结构化越野驾驶条件的自动驾驶车辆，需要在其整体系统中增加一个功能模块，以补偿由于车轮过度打滑而产生的定位和轨迹跟踪误差。车轮打滑既受车辆特性（例如车辆重量、速度、轮胎充气情况）的影响，也受行驶路面类型和特性（例如沙子密度、岩石摩擦力、地形不平整度）的影响。在执行自动驾驶越野任务时，地面车辆可能会被分配到具有高陷入泥泞或湿滑区域风险的具有挑战性的目标位置[1]。因此，车辆必须在一定程度的确定性内规划轨迹，以避免地形引起的打滑，或者继续行驶并通过对速度的控制来补偿打滑。

并且扭矩。无论哪种方式，这两种方法都需要一个可靠的车轮打滑预测模型，这凸显了这些模型在越野导航中的关键作用。从方法和传感器的角度来看，车轮打滑预测可分为三类：基于本体感觉传感器的、基于外部感觉传感器的和基于模型的[2]。在自动驾驶汽车的背景下，本体感觉传感器是车载传感器，例如惯性测量单元（IMU）、全球定位系统（GPS）和车轮编码器，用于测量车辆的状态。当车辆穿越特定地形时，这些传感器会收集当前时间的数据，并将其输入预测模型以输出估计的瞬时车轮打滑量。由于这种技术直接测量车轮与表面之间的物理相互作用，因此被认为是滑移估计最准确的方法。然而，这种方法无法进行提前（提前）的滑移预测。另一方面，基于外部感觉传感器的方法可以实时预测机器人在目标（可能较远）位置的潜在未来滑移。然而，现有的基于外部传感器的方法通常依赖视觉传感器，仅基于地形表面的特性，正如文献[3]、[4]所指出的那样，这可能不足以进行精确的滑移估计。

结合上述两种方法，我们提出了一种实时滑移预测机制，该机制融合了深度学习和机器学习技术，以学习运动数据与地形几何形状之间的相关性。这使得能够创建一个轮滑估计模型，该模型可以集成到自主导航堆栈中。更具体地说，本文的主要贡献有三个方面：

与现有的主要针对火星车或差速驱动机器人进行滑移估计的研究不同，本研究的主要目的是为类汽车机器人建立一个滑移估计模型，该模型可用于分析滑移风险水平并改进路径规划。为此，我们利用先进的模拟器（CM-Labs Vortex Studio）构建了一个丰富的数据集，其中考虑了四种不同的地形（冰面、公路、泥地和沙地）。为了模拟真实世界的状况，通过考虑各种驾驶场景、速度和操作来丰富生成的数据。模拟数据可在 GitHub 上公开获取。

2) 我们提出了一种混合深度学习滑移预测方法，该方法首先需要识别地形类型。为此，我们开发了一个轻量级的卷积神经网络（CNN）模型，

Mustofa Basri, Areg Karapetyan, Bilal Hassan, Majid Khonji, and Jorge Dias are with EECS Department, Khalifa University, Abu Dhabi, UAE (emails: {100059870, areg.karapetyan, bilal.hassan, majid.khonji, jorge.dias}@ku.ac.ae). This work was supported by Khalifa University under awards CIRA-2020-286, KKJRC-2019-Trans1, and KU Center for Robotics and Autonomous Systems (KUCARS).

1 see https://github.com/must23/Offroad_Motion_Dataset.

授权许可使用范围限于：意大利技术研究院（IIT - Istituto Italiano di Tecnologia）。于 2026 年 1 月 12 日 02:15:09 UTC 从 IEEE Xplore 下载。使用受限。

名为 TerrainNet 的模型能够利用地理数据（图像）准确识别地形。该模型采用空洞卷积和跳跃连接，从而具备强大的多尺度特征提取能力。

3）为作对比，我们训练并评估了三种基于机器学习的滑移估计模型（多层感知机、随机森林和梯度提升树）的性能。所构建的模型应用于一个包含 504,000 个样本的大规模数据集，以估计纵向滑移。仿真结果表明，所提出的方法在精确估计越野条件下的车轮滑移方面十分有效（平均均方根误差小于 0.03）。

II. 相关工作

关于预测车轮打滑的研究中，最常被提及的有[5]和[6]两篇文献。它们利用视觉信息作为输入，通过实施基于学习的模型来对地形类型进行分类，并预测探测车的车轮打滑情况。[7]中的作者在[5]的基础上进行了拓展，提出了对人工神经网络和局部加权投影回归实现模型的训练至关重要的新输入变量。Skonieczny 等人在[8]中进一步研究了通过寻找车辆前方坡度与打滑之间的关系来估算车轮打滑的方法。他们提出了一种基于简单数据结构的车轮打滑预测方法，用于建立打滑与坡度之间的模型。在另一种模型中，[9]和[10]的作者提出了一种基于高斯过程模型的算法，用于预测打滑分布，以捕捉估计的不确定性方面。[11]中的作者同样使用高斯过程模型训练模型，并将其与基于贝叶斯过程的遗传算法进行了比较。高斯过程模型提供了良好的估计精度；然而，与基于神经网络的机器学习模型相比，它不够稳定，并且计算复杂度更高。

在基于机器学习的模型中，Gonzales 等人在[12]中对一些著名的机器学习算法进行了全面的比较，以估计与单个车轮和行星探测车相关的离散值形式的车轮打滑情况。此外，在[13]中，作者们应用无监督机器学习来估计相同设置下的车轮打滑情况。Liu 等人在[14]中回顾了一些关于车轮打滑预测以及在履带车辆上使用机器学习方法的工作。该研究探讨了将机器学习用于履带车辆动力学的可能性，履带车辆的速度和机动性高于探测车。确切地说，该研究采用卷积神经网络（CNN）进行道路识别，并使用分段回归方法来估计每种道路类型的打滑情况。

从另一个角度来看，Xu 等人在[15]中开发了仅利用加速度来预测车轮打滑的新传感器系统。[16]和[17]中提出了预测车辆侧滑角和实际速度的显著工作，这些是车轮打滑的关键输入特征。进一步探索深度学习的能力，[18]中的作者将传统机器学习方法（如支持向量机（SVM））与深度神经网络（DNN）和卷积神经网络（CNN）在车轮打滑估计和地形识别方面的性能进行了比较。[19]中的作者通过使用额外的输入特征和一种称为循环深度神经网络的时间序列模型来扩展这项工作，该模型考虑了先前的数据序列来预测未来的车轮打滑。结果表明深度学习在车轮打滑预测方面具有良好的应用前景。然而，在[18]中，所提出的深度神经网络仅调整了一个隐藏层，这可能没有充分利用 DNN 的潜力。在[19]中，重点是估计两轮移动机器人在车轮打滑情况下的速度和偏航角，但并未明确估计车轮打滑本身。此外，这些研究均未在类似汽车的机器人上对其模型进行测试，也未在沙漠等非结构化环境中进行测试，在这种环境中，地形的可通行性难以预测。鉴于这些不足，本文对不同的机器学习算法进行了比较，这些算法具有足够的输入特征，能够捕捉到车轮与土壤之间相互作用所产生的非线性滑移。

III. 数据集与方法

在本节中，我们将讨论用于估计车轮滑移的所提框架的工作机制，如图 1 所示。各阶段的说明将在以下各小节中给出。

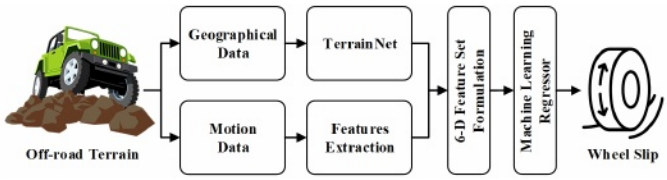

图 1. 所提滑移估计框架的框图。

A. 数据生成

本研究的数据集是使用 CM-Labs Vortex Studio 模拟软件生成的[2]。我们考虑了四种不同的地形（冰面、道路、泥地和沙地）来提取数据样本。此外，我们使用了库仑和贝克 [20] 的地面力学模型来调整轮胎参数。而且，我们将车辆动力学配置为前轮驱动模型[3]，以获取多种运动数据读数，包括里程计、速度、车轮位置、角速度、扭矩、转向角、加速度等等。另外，在车辆前方放置了模拟的三通道（RGB）相机来捕获地理数据（帧）。此外，我们根据前轮 (F_z) 和后轮 (R_z) 之间的 z 轴位置以及前轮和后轮之间的距离（l），按照公式（1）计算了每个时刻的坡度值：

$$\theta = \sin^{-1}\left(\frac{F_z - R_z}{l}\right). \tag{1}$$

[2] 漩涡工作室：https://www.cm-labs.com/vortex-studio/ 。

[3] 模块化车辆系统：前轮驱动车辆。

授权许可使用范围限于：意大利技术研究院（IIT - Istituto Italiano di Tecnologia）。于 2026 年 1 月 12 日 02:15:09 UTC 从 IEEE Xplore 下载。使用受限。

此外，对于每种地形类型，我们针对 14 种不同的设置驾驶车辆，考虑了坡度角度、行驶速度和操作动作。在每种设置下，我们以 60 赫兹的频率记录了 150 秒的地理数据，并导出了相应的运动数据读数。通过这种方式，我们为每种地形获得了总计 126,000 个读数。此外，还考虑了模拟器中前轮的纵向滑移值以作为真实值。滑移值在 0 到 1 之间，1 表示最大滑移。公式（2）定义了滑移的计算方法，其中 s 表示滑移，r 表示车轮半径，v 表示实际速度，ω 表示角速度：

$$s = \frac{(\omega \cdot r) - v}{\max(\omega \cdot r, v)}. \tag{2}$$

B. 特征提取

在从运动学传感器获取运动数据后，我们确定了最相关且独特的参数作为训练滑移估计模型的特征。我们使用斯皮尔曼相关距离来降低运动数据的维度，并选择了五个最显著的特征：车轮扭矩、角速度、x 轴线速度、z 轴线速度和坡度。此外，我们还将地形类型作为第六个也是最后一个特征，该特征从地理数据中提取。为此，我们实现了一个轻量级的卷积神经网络（CNN）模型，用于实时对地形进行分类。CNN 模型预测的标签以整数形式存储，其中 1、2、3 和 4 分别代表冰面、道路、泥地和沙地。实例 i 对应的 6 维特征集表示为：

$$F(i) = \{F_m(i), F_g(i)\}, \qquad i = 1, 2, 3, \ldots, N \tag{3}$$

$$F_m(i) = \{f_i^1, f_i^2, f_i^3, f_i^4, f_i^5\}, \tag{4}$$

$$F_g(i) = \{f_i^6\}, \tag{5}$$

其中 F_m 表示从运动数据中提取的五个特征，F_g 表示从地理数据中提取的一个特征（地形类型），N 表示数据集中的实例总数。F 是通过将 F_m 和 F_g 拼接而成的 6 维特征集。接下来，我们将详细介绍所提出的用于识别地形的 CNN 模型。

C. 所提议的地形网络模型

所提出的地形识别网络（TerrainNet）设计得极为精简（52 层），适合实时应用。它有 14 层卷积层，仅使用约 30 万个参数。与传统的地形识别卷积神经网络（CNN）通常仅依赖于前馈处理不同，所提出的 TerrainNet 模型是一个有向无环图网络，它融合了空洞空间金字塔池化（ASSP）[21] 模块和残差连接，以逐步提升网络的特征学习能力，从而实现地形的准确识别。

所提出的 TerrainNet 模型的前五个模块（B1、B2、B3、ASPP、B4）作为收缩路径，通过连续执行卷积（C）和最大池化（MP）操作，使网络能够学习每种地形类型的区分特征。此外，我们在每次卷积操作后应用批量归一化（BN）和修正线性单元激活（ReLU），以对输入进行归一化并过滤掉负值。最后一个模块（B5）包括全局平均池化（GAP）、全连接（FC）、softmax 和分类层。它使用 softmax 置信度得分对帧进行分类。所提出的 TerrainNet 模型的详细分层排列如表 I 所示。

表 I
所提出的地形识别网络的分块配置。

街区	层操作	[S, P, M]	输出大小	参数
输入	地形图像	–	299×299×3	0
B1	(1 c + BN + ReLU)×2 (2 mp)	[2, “相同”, 16]	75×75×16	2,832
		[2, 0, 16]	三十七乘三十七乘十六	0
B2	[1C+BN+ReLU]×2	[1, “相同”, 16]	三十七乘三十七乘十六	4,704
B3	(1 c + BN + ReLU)×3 (2 mp)	[1, “相同”, 48]	三十七乘三十七乘四十八	18,816
		[2, 0, 48]	18×18×48	0
ASPP	[3C+BN+ReLU]×4 [DC]	[1, “相同”, 12]	18×18×12	20,884
		–	18×18×48	0
B4	[1C+BN+ReLU]×3	[2, “相同”, 96]	3×3×96 等于 864	208,224
B5	缝隙	–	1×1×96	0
	FC	–	1×1×4	388
	Softmax	–	1×1×4	0
	分类	–	1×1×4	0

卷积操作使用 3×3 的卷积核，所有最大池化操作采用 2×2 的卷积核，空洞卷积操作使用具有不同膨胀率（1、3、5 和 7）的 3×3 卷积核。S = 步幅，P = 填充，M = 通道数。

为了训练 TerrainNet 模型，我们首先将地理数据（帧）调整为 299×299 的统一分辨率，然后将每种地形的总数据（100800 个样本）按 80:20:20 的比例划分为训练、验证和测试集。此外，我们采用交叉熵损失来规范 TerrainNet 的训练过程，其表达式为：

$$\mathcal{L}_{ce} = -\sum_{u=1}^{I}\sum_{v=1}^{C} \phi_{uv} \ln \psi_{uv}, \tag{6}$$

其中 C 和 I 分别表示类别数量和总实例数。$\boxtimes_{uv}$ 是表示第 u 个实例属于第 v 个类别的真实标签，而 ψuv 是 TerrainNet 模型的输出，表示网络概率，即它将 u^{th} 输入分配给 v^{th} 类别。此外，在训练阶段采用带有动量的随机梯度下降（SGDM）优化器来更新 TerrainNet 的参数。我们将小批量大小指定为 128，整个训练过程在 30 个周期内完成，每个周期有 2835 次迭代。此外，在训练过程中我们指定固定的学习率为 0.01。

D. 基于机器学习的车轮打滑估计

在这项研究中，我们评估了三种回归算法的性能，分别是多层感知器（MLP）、

授权许可使用范围限于：意大利技术研究院（IIT - Istituto Italiano di Tecnologia）。于 2026 年 1 月 12 日 02:15:09 UTC 从 IEEE Xplore 下载。使用受限。

随机森林（RF）和极端梯度提升（XGB），用于估计车轮滑移值。表 II 展示了本研究中用于回归模型训练和验证的数据分布情况。接下来，我们将对这三种算法进行简要说明。

*1) 多层感知机(MLP):*MLP 是一种监督学习方法，通过在数据集上训练来学习映射函数 $f(\cdot) = K^m \rightarrow K^o$，其中 m 和 o 分别是输入和输出的维度。对于一组特征 $\{f_1, f_2, \ldots, ff_n\}\}$ 和目标 t，可以训练用于回归层的非线性函数逼近器。这

表二
用于基线回归模型训练和验证目的的数据集详情

子集	多层感知机	射频	XGB
训练	322,560	403,200	403,200
验证	80,640	-	-
测试	100,800	100,800	100,800
总计	504,000	504,000	504,000

所采用的多层感知机（MLP）架构包含 4 个隐藏层，分别有 50、60、40 和 40 个神经元。输入层包含六个神经元 f_1 至 f_6，对应六个特征，输出层包含一个神经元。隐藏层中的每个神经元都通过加权线性求和对前一层的值进行转换，然后进行非线性激活。在所提出的 MLP 结构中，我们在隐藏层使用了 Swish 激活函数，在输出层使用了 Sigmoid 函数。我们采用 Adam 优化器 [22] 和平均绝对误差作为损失函数，对 MLP 模型进行了 100 个周期的训练，每个小批量的大小为 100。MLP 架构的设计和超参数是根据验证集上的最佳输出性能通过经验确定的。

*2) 随机森林:*随机森林（RF）[23] 由多棵决策树组成。基于决策树的模型使用树形结构来表示数据，其中每个节点对应一个目标类别，属性被描述为内部节点。每个分支表示其父节点属性的可能价值。随机森林通过组合多棵决策树的预测结果来降低每棵决策树的方差，从而实现稳健的性能。构建随机森林模型的一个重要方面是选择决策树的数量和最大深度值。在本文中，我们构建了一个包含 100 棵决策树的随机森林模型，每棵树由上述六个特征对应的六个属性构成。最大深度设置为 100，其余模型参数均采用 scikit-learn 包中定义的默认值[4]。随机森林的参数是基于 5 折交叉验证来设置的。

*3)极端梯度提升:*与随机森林类似，XGB 是一种基于决策树的集成机器学习技术 [24]。XGB 采用提升算法来提高预测准确性。在增加错误分类训练样本权重和降低正确分类样本权重之间存在权衡。为了降低错误分类的发生率，权重较高的训练样本会以更高的关注度多次处理。这一特性使 XGB 能够超越单个决策树模型的最终准确率。在训练 XGB 模型时，我们将最大深度设为 100，其余参数设置为 scikit-learn 包中定义的默认值[5]。与随机森林一样，XGB 的参数是基于 5 折交叉验证来设置的。

IV. 模拟设置与结果

在本节中，将对所提出的框架在精确识别地形和估计车轮打滑方面的性能进行评估。接下来，我们首先列出所采用的系统参数和指标，然后报告所进行的数值研究的结果。

A. 系统和软件规格

所提出的框架已在配备英特尔酷睿 i7-10750H 处理器（2.60GHz）、16GB 内存、NVIDIA RTX 2060 显卡（cuDNN v7.5）和 CUDA 版本 11.3 的机器上使用 TensorFlow 2.9.1 和 Python 3.10.5 实现。

B. 绩效指标

我们使用混淆矩阵来评估所开发的卷积神经网络在地形分类中的性能。至于滑移估计，预测滑移值（yp）与真实滑移值（yg）之间的误差通过三个 commonlypemployed 指标来衡量，即平均绝对误差（MAE = 1/N ∑N i=1 |yp - yg|）、均方误差（MSE = 1/N ∑N i=1 （yp - yg）2）和均方根误差（RMSE = √(MSE)）。

1 乘以从 i 等于 1 到 n 的求和（yi 减去 yi）的平方，再乘以 g p 2

$y_i^p|$)，均方误差（MSE = N √

均方根误差（RMSE = MSE）

C. 地形分类性能

我们首先使用包含 100800 张图像的测试数据集对 TerrainNet 与其他轻量级预训练模型 [25] - [28] 的分类性能进行了比较，这些图像均匀分布在四个地形类别（冰、道路、泥地和沙地）中。结果如图 2 所示，可以看出训练好的 TerrainNet 表现卓越，仅将 5 张图像分类错误，其余 100795 张图像均正确分类，如图 4 a 和图 4 b 所示。此外，图 3 展示了从每个地形类别中随机选取的图像以及类别激活图和置信度得分。在这里，我们可以观察到所提出的 TerrainNet 的分类决策主要受车辆行驶表面的影响，并且通常对地形图像的分类置信度得分较高。此外，我们还从计算复杂度方面将 TerrainNet 的性能与最先进的（SOTA）方法进行了比较。结果见表 III，其中可以看出所提出的 TerrainNet 模型所需的参数比下一个最简约的架构（ShuffleNet [28]）少 366%（仅 30 万个）。此外，处理一帧图像需要 10.17 毫秒，每秒可处理 98 帧，这使其适用于实时应用。

4 RF training parameters: scikit-learn RF parameters.

5 XGB training parameters: scikit-learn XGB parameters.

授权许可使用范围限于：意大利技术研究院（IIT - Istituto Italiano di Tecnologia）。于 2026 年 1 月 12 日 02:15:09 UTC 从 IEEE Xplore 下载。使用受限。

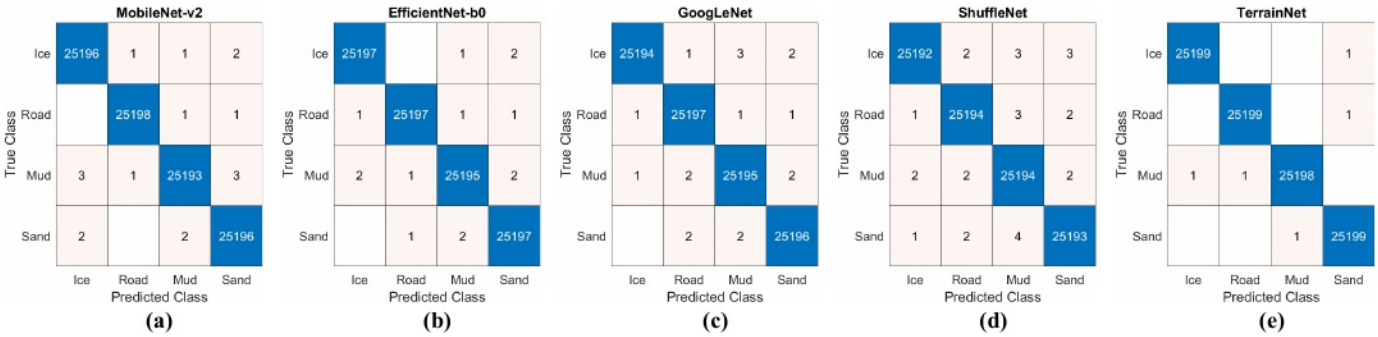

图 2. 使用混淆矩阵比较 TerrainNet 分类性能与最先进的方法。（a）MobileNet-v2 [25]，（b）EfficientNet-b0 [26]，（c）GoogleNet [27]，（d）ShuffleNet [28]，（e）TerrainNet。

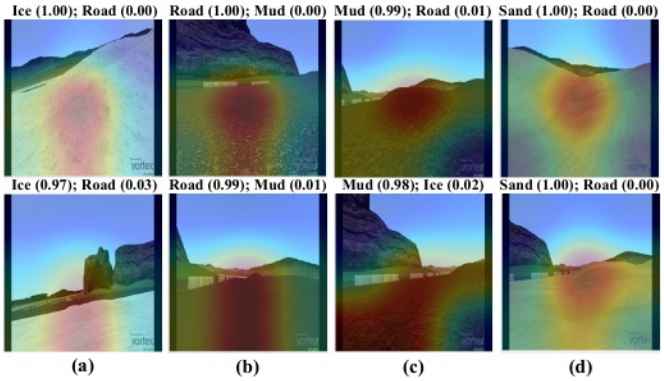

图 3. 由训练好的 TerrainNet 模型正确分类的每种地形类型随机选取图像的类激活图和置信度得分。（a）冰，（b）道路，（c）泥地，（d）沙地。

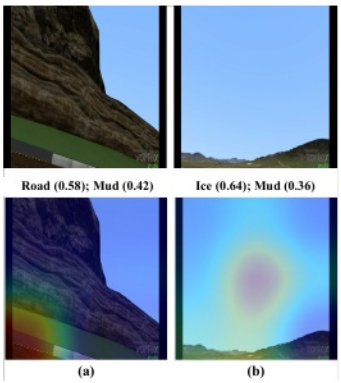

图 4. 经过训练的 TerrainNet 模型错误分类的样本，以及对应的类别激活图和置信度得分。（a）被误分类为道路的泥地图像，（b）被误分类为冰面的泥地图像。

D. 车轮打滑估计

在本节中，我们使用包含 100800 个样本的整个测试数据集对回归方法（MLP、RF 和 XGB）的滑移估计性能进行了比较。每个模型的滑移预测结果在图 5 中进行了可视化展示，并在表 IV 中以表格形式列出以作比较。特别地，图 5 的子图分别展示了应用 MLP、XGB 和 RF 方

表三
在计算复杂度方面将所提出的地形网络模型与其他最先进的方法进行比较

模型 Model	输入分辨率 Resolution	计算复杂度（使用 GTX 3090）Computational Complexity (with GTX 3090)		
		参数量 (M) Parameters (M)	运行时间 (ms) Runtime (ms)	帧率 # FPS
MobileNet-v2 [25]	$224\times224\times3$	3.5	11.94	83
EfficientNet-b0 [26]	$224\times224\times3$	5.3	12.23	81
GoogLeNet [27]	$224\times224\times3$	7.0	13.48	74
ShuffleNet [28]	$224\times224\times3$	1.4	11.35	88
TerrainNet	$299\times299\times3$	0.3	10.17	98

法在沙地、泥地、公路和冰面地形上估计车轮滑移的结果。沙地和泥地的滑移范围比公路和冰面地形更广。这可能是由于模拟器中一些较高的地形力学属性值（如摩擦力和压力下陷设置）影响了车辆的运动。这些结果反映了现实世界中车轮与土壤的物理相互作用。表 IV 列出了每种回归方法在不同地形下的估计性能，使用了不同的指标。从结果可以看出，RF 和 XGB 方法的性能优于 MLP 方法。此外，如图 5（a）所示，与图 5（b）和（c）中的 XGB 和 RF 方法相比，MLP 方法存在较多的异常值。这或许是因为调整多层感知机（MLP）的超参数以确保其性能达到最优是件难事。此外，我们注意到回归方法在不同地形上的表现有所不同。以均方根误差（RMSE）为衡量标准，随机森林（RF）在冰面和道路上的表现最佳，而梯度提升树（XGB）在泥地和沙地上的估计效果最好。再者，综合考虑四种地形的表现，从均方误差（MSE）和均方根误差（RMSE）这两个指标来看，随机森林（RF）和梯度提升树（XGB）方法的表现相当。不过，就平均绝对误差（MAE）这一指标而言，梯度提升树（XGB）的表现略优于随机森林（RF），高出约 6%。最后，如表 V 所示，我们展示了所提出的方法与现有最佳方法在越野条件下估计纵向滑移的对比情况。表 V 中的对比是间接的，因为据我们所知，目前没有公开的数据集可用作评估滑移估计模型的基准。从表 V 的结果可以看出，本研究中训练的梯度提升树（XGB）回归器实现了

授权许可使用范围限于：意大利技术研究院（IIT - Istituto Italiano di Tecnologia）。于 2026 年 1 月 12 日 02:15:09 UTC 从 IEEE Xplore 下载。使用受限。

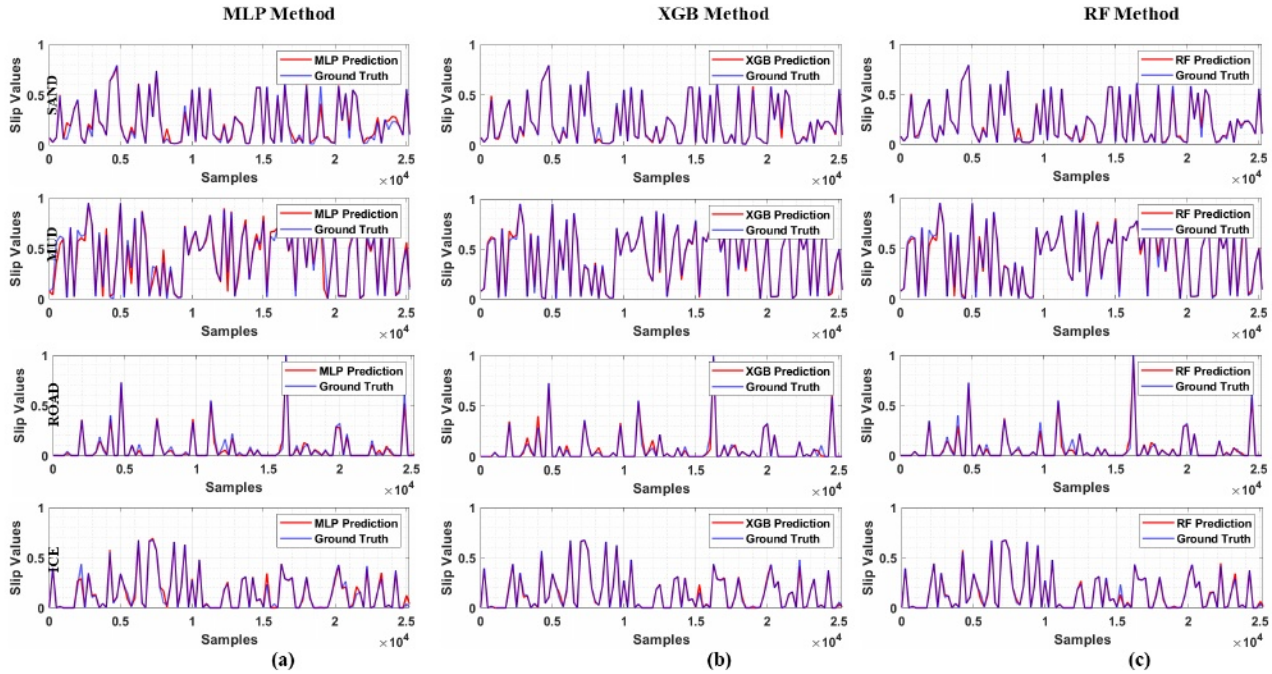

图 5. 使用（a）多层感知机（MLP）、（b）梯度提升树（XGB）、（c）随机森林（RF）预测方法对每种地形类型测试样本的预测车轮滑移值与实际值（真实值）的对比。

表 IV

不同回归器的地形滑移估计性能。最佳和次佳结果分别以粗体和显示。

分别用下划线标出。

方法	冰			道路			泥巴			沙子			联合的		
	MAE	均方误差	均方根误差	MAE	均方误差	均方根误差	MAE	均方误差	均方根误差	MAE	均方误差	均方根误差	MAE	均方误差	均方根误差
多层感知机	0.0126	0.0029	0.0543	0.0118	0.0017	0.0413	0.0288	0.0029	0.0534	0.0221	0.0023	0.0485	0.0188	0.0025	0.0494
射频	0.0050	0.0005	0.0221	0.0078	0.0007	0.0261	0.0105	0.0009	0.0301	0.0117	0.0014	0.0368	0.0088	0.0009	0.0288
XGB	0.0049	0.0005	0.0227	0.0077	0.0007	0.0262	0.0092	0.0008	0.0276	0.0114	0.0013	0.0366	0.0083	0.0008	0.0283

滑移估计性能卓越，均方根误差仅为 0.0283。这种性能的提升可归因于用于训练 XGB 模型所选择的特征，包括对地形类型的预先识别，这使得每种地形的估计滑移值与实际滑移值之间的误差更低。

表 V

所提滑移估计结果与其他结果的比较

最先进方法

参考文献	方法	MAE	均方误差	均方根误差
[7]	人工神经网络	0.0418	-	0.0571
	局部加权投影回归	0.0470	-	0.0509
[15]	人工神经网络	-	-	0.0488
[29]	反向传播（BP）	0.0316	-	0.0417
	遗传算法 - BP 神经网络	0.0311	-	0.0406
[30]	高斯过程回归	-	-	0.0460
我们的	随机森林	0.0088	0.0009	0.028
	极端梯度提升	0.0083	0.0008	0.0283

V. 结论

本文提出了一种用于越野条件下的混合深度学习滑移预测模型。所提出的框架首先使用高效轻量级的卷积神经网络（CNN）识别地形。此外，我们还确定了从本体感受传感器中提取的有前景的特征，用于在各种越野环境中训练三个机器学习回归器（多层感知器（MLP）、随机森林（RF）和梯度提升树（XGB））。仿真结果表明，基于机器学习的回归器具有较高的准确性，在精确估计车辆运动过程中的车轮滑移行为方面具有良好的潜力。当前研究的主要局限性在于使用了模拟数据。然而，在未来的工作中，我们打算纳入不同条件下的真实世界训练样本，以评估所提出方法在指导路径规划和监测滑移方面的潜力。

参考文献

[1] R. E. Arvidson, K. D. Iagnemma, M. Maimone, A. A. Fraeman, F. Zhou, M. C. Heverly, P. Bellutta, D. Rubin, N. T. Stein, J. P. Grotzinger, and A. R. Vasavada, “Mars science laboratory curiosity rover megaripple crossings up to sol 710 in gale crater,” *Journal of Field Robotics*, vol. 34, no. 3, pp. 495–518, 2017.

[2] R. Gonzalez and K. Iagnemma, “Slippage estimation and compensation for planetary exploration rovers. state of the art and future challenges,” *Journal of Field Robotics*, vol. 35, no. 4, pp. 564–577, 2018.

[3] Shamrao, C. Padmanabhan, S. Gupta, and A. Mylswamy, “Estimation of terramechanics parameters of wheel-soil interaction model using particle filtering,” *Journal of Terramechanics*, vol. 79, pp. 79–95, 10 2018.

授权许可使用范围限于：意大利技术研究院（IIT - Istituto Italiano di Tecnologia）。于 2026 年 1 月 12 日 02:15:09 UTC 从 IEEE Xplore 下载。使用受限。

[4] W. Smith and H. Peng, "Modeling of wheel–soil interaction over rough terrain using the discrete element method," *Journal of Terramechanics*, vol. 50, p. 277–287, 10 2013.

[5] A. Angelova, L. Matthies, D. Helmick, and P. Perona, "Learning and prediction of slip from visual information," *Journal of Field Robotics*, vol. 24, no. 3, pp. 205–231, 2007.

[6] D. Helmick, A. Angelova, and L. Matthies, "Terrain adaptive navigation for planetary rovers," *Journal of Field Robotics*, vol. 26, no. 4, pp. 391– 410, 2009.

[7] H. Ma, H. Yang, Q. Li, and S. Liu, "A geometry-based slip prediction model for planetary rovers," *Computers & Electrical Engineering*, vol. 86, p. 106749, 2020.

[8] K. Skonieczny, D. K. Shukla, M. Faragalli, M. Cole, and K. D. Iagnemma, "Data-driven mobility risk prediction for planetary rovers," *Journal of Field Robotics*, vol. 36, no. 2, pp. 475–491, 2019.

[9] H. Inotsume and T. Kubota, "Adaptive terrain traversability prediction based on multi-source transfer gaussian processes," in *2021 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*. IEEE, 2021, pp. 2297–2304.

[10] M. Endo, S. Endo, K. Nagaoka, and K. Yoshida, "Terrain-dependent slip risk prediction for planetary exploration rovers," *Robotica*, vol. 39, no. 10, pp. 1883–1896, 2021.

[11] T. Zhang, S. Peng, Y. Jia, J. Sun, H. Tian, and C. Yan, "Slip estimation model for planetary rover using gaussian process regression," *Applied Sciences*, vol. 12, no. 9, p. 4789, 2022.

[12] R. Gonzalez, S. Chandler, and D. Apostolopoulos, "Characterization of machine learning algorithms for slippage estimation in planetary exploration rovers," *Journal of Terramechanics*, vol. 82, pp. 23–34, 2019.

[13] J. Kruger, A. Rogg, and R. Gonzalez, "Estimating wheel slip of a planetary exploration rover via unsupervised machine learning," in *2019 IEEE Aerospace Conference*. IEEE, 2019, pp. 1–8.

[14] J. Liu, B. Wang, H. Liu, and F. Mao, "Slip estimation for autonomous tracked vehicles via machine learning," in *2021 IEEE Intelligent Vehicles Symposium (IV)*. IEEE, 2021, pp. 91–98.

[15] N. Xu, Z. Tang, H. Askari, J. Zhou, and A. Khajepour, "Direct tire slip ratio estimation using intelligent tire system and machine learning algorithms," *Mechanical Systems and Signal Processing*, vol. 175, p. 109085, 2022.

[16] L. P. González, S. S. Sánchez, J. Garcia-Guzman, M. J. L. Boada, and B. L. Boada, "Simultaneous estimation of vehicle roll and sideslip angles through a deep learning approach," *Sensors*, vol. 20, no. 13, p. 3679, 2020.

[26] M. Tan and Q. Le, "Efficientnet: Rethinking model scaling for convolutional neural networks," in *International conference on machine learning*. PMLR, 2019, pp. 6105–6114.

[17] A. Bonfitto and S. Feraco, "A data-driven method for vehicle speed estimation," *Communications-Scientific letters of the University of Zilina*, vol. 23, no. 3, pp. B165–B177, 2021.

[18] R. Gonzalez and K. Iagnemma, "Deepterramechanics: Terrain classification and slip estimation for ground robots via deep learning," *arXiv preprint arXiv:1806.07379*, 2018.

[19] ·I. Özçil, A. B. Koku, and E. ·I. Konukseven, "Slippage estimation of two wheeled mobile robot using recurrent deep neural network," in *Proceedings of the 2019 International Conference on Artificial Intelligence, Robotics and Control*, 2019, pp. 7–13.

[20] M. G. Bekker, "Introduction to terrain-vehicle systems. part i: The terrain. part ii: The vehicle," Michigan Univ Ann Arbor, Tech. Rep., 1969.

[21] L.-C. Chen, Y. Zhu, G. Papandreou, F. Schroff, and H. Adam, "Encoder-decoder with atrous separable convolution for semantic image segmentation," in *Proceedings of the European conference on computer vision (ECCV)*. Springer, 2018, pp. 801–818.

[22] D. P. Kingma and J. Ba, "Adam: A method for stochastic optimization," *arXiv preprint arXiv:1412.6980*, 2014.

[23] L. Breiman, "Random forests," *Machine learning*, vol. 45, no. 1, pp. 5–32, 2001.

[24] T. Chen and C. Guestrin, "Xgboost: A scalable tree boosting system," in *Proceedings of the 22nd acm sigkdd international conference on knowledge discovery and data mining*, 2016, pp. 785–794.

[25] M. Sandler, A. Howard, M. Zhu, A. Zhmoginov, and L.-C. Chen, "Mobilenetv2: Inverted residuals and linear bottlenecks," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2018, pp. 4510–4520.

[27] C. Szegedy, W. Liu, Y. Jia, P. Sermanet, S. Reed, D. Anguelov, D. Erhan, V. Vanhoucke, and A. Rabinovich, "Going deeper with convolutions," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2015, pp. 1–9.

[28] X. Zhang, X. Zhou, M. Lin, and J. Sun, "Shufflenet: An extremely efficient convolutional neural network for mobile devices," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2018, pp. 6848–6856.

[29] T. Zhang, S. Peng, Y. Jia, H. Tian, J. Sun, and C. Yan, "Slip estimation for mars rover zhurong based on data drive," *Applied Sciences*, vol. 12, no. 3, p. 1676, 2022.

[30] C. Cunningham, M. Ono, I. Nesnas, J. Yen, and W. L. Whittaker, "Locally-adaptive slip prediction for planetary rovers using gaussian processes," in *2017 IEEE International Conference on Robotics and Automation (ICRA)*. IEEE, 2017, pp. 5487–5494.

授权许可使用范围限于：意大利技术研究院（IIT - Istituto Italiano di Tecnologia）。于 2026 年 1 月 12 日 02:15:09 UTC 从 IEEE Xplore 下载。使用受限。